



AI 创业风向标

Anthropic 智能体实际使用报告 深度解读

基于公共 API 交互情况统计

原报告地址: <https://anthropic.com/research/measuring-agent-autonomy>

“下一代 300 个独角兽，藏在‘空白行业版图’里”

300+

潜在独角兽

📖 创业藏宝图

拆解 AI 智能体实际落地场景，不仅仅是技术数据。

分享人

碳归同传





现状洞察

AGENT

01

数据里的

“烟囱”与“荒原”

Agent 到底被用在哪?

→ 进入第一部分

数据里的 烟囱与荒原

极度不均衡的流量分布

软件工程 (Coding)

49.7%

半壁江山·算力黑洞


一家独大

VS

其他所有行业总和

呈现极度碎片化的长尾分布

In what domains are agents deployed?



核心洞察

数据来源: ANTHROPIC

数据里的“烟囱”与“荒原”

垂直领域的“低渗透”真相

核心渗透率数据

教育

1.8%

医疗

1.0%

法律


0.9%

物流

0.8%

AGENT DEPLOYMENT

In what domains are agents deployed?



“绝大多数行业，连 AI Agent 的面都还没见着。”

— 16个垂直行业渗透率均低于 9%

数据背后的信号

“从“无人区”看到的真实逻辑

现状

几乎**空白**的
行业版图



“连一分钟的流程
都没跑通过”

核心判断

~~不是没有需求，~~
是未被开发。

🔧 这里是最大的 Alpha

机会藏在没人愿意啃的
“硬骨头”里

— YC CEO 的判断

下一代 300个 独角兽

逻辑



SAAS 1.0

替代 软件

⋮



AI 2.0

替代 **操作软件的人**

↗ 天花板高 10 倍

300


预测独角兽数量

“

“盯住那片
空白区域”



Garry Tan / YC



Tool Calls 祛魅

技术指标解读：透视 Agent 真实活跃度



CORE METRIC

工具 调用量

Metric: tool_calls

"这不仅是一个数字，更是 Agent 智能体在实际场景中 思考与执行 的痕迹。"

✗ 非 企业数量

Adoption (普及率)

不代表有多少家公司接入，也不代表市场覆盖率。



✓ 是 活动频次

Activity (活跃度)

反映 Agent 真正“干活”的频率。软件工程的高分，源于其 天然的高频交互 属性。



LH9ISN1

为何软件工程先爆发？

深度解析：从“代码回滚”到“信任成本”的行业鸿沟

软件工程

</>

01

高容错性 (可回滚)

代码写错成本极低，Git 回滚即可复原。失败仅仅是“重试”的开始。

02

自动化验证闭环

单元测试、CI/CD 流水线可自动拦截 90% 的低级错误。

垂直行业 (医疗/法律)

⚖️

01

零容错 (无限责任)

医疗误诊、法律取证错误将面临诉讼与生命风险。没有“撤回”键。

02

依赖专家复核

无法完全自动化，必须引入昂贵的人类专家进行二次确认。



核心洞察：护城河不在模型，在于谁能搞定低容错场景的“信任”问题。

02

PART

概念可视化：能力势能差



实际落地

TERM

Deployment Overhang

部署积压

“模型能力已到位，
但在人类社会的
信用体系里依然赤字。”

- AI 从业者视角解析

METR 评估基准

▣ 理想状态下的能力上限



5 小时

人类连续任务时长

Claude 目前可独立完成人类需耗时约 5 小时的长程任务。

工作量基准

● 独立完成率

50%



✓ 核心定义

指在无人类干预的理想状态下，模型所能触达的能力边界。

“这相当于半个全职员工的一天工作量”



现实授权天花板

从理论 5 小时到现实 45 分钟：信任的物理边界

理论能力

5h

模型推理极限

6倍落差


99.9% 分位用户数据

45min

现实授权边界

Claude Code 轮次持续时间趋势

数据来源: Anthropic




部署积压

Deployment Overhang 定义

核心概念

模型能力

Model Capability



Huge Gap

滞后

用户授权

User Authorization

本质洞察

✓ 技术已就位

⚠ 信任在滞后

商业机会

消除 “信任剪刀差”

将 45 分钟的犹豫
转化为 5 小时的价值



增长的驱动力

INSIGHT

Human Adaptation > Model Capability

DURATION


25 → 45

分钟 (3个月内翻倍)

DATA EVIDENCE

How long does Claude Code work before stopping?

(99.9th percentile)



🔍 特征：曲线平滑，无突变

“

“驱动增长的不是模型变强，
而是人类在一次次协作中，学
会了慢慢松手。”

Human-AI Trust Loop

两极分化

数据分布的真相

INSIGHT

中位数

Median User

45秒

🔍 试探性使用

绝大多数人仅停留在 "Hello World" 的浅层交互。

TOP 99.9% 头部用户

45分钟

| 深度生产力场景



KEY TAKEAWAY

长尾效应极强, 精英用户正在突围。



内部数据佐证

内部效能演进

指标 01：能力

最困难任务
成功率

2倍

指数级跃升

指标 02：信任

人工介入次数 (每会话)

~~5.4~~

→

3.3 次

💡 洞察：身份转变

AI 正从 **实习生** 变为 **熟练工**

企业服务核心 KPI

↓ 降低介入率

信任即护城河

——产品经理的新北极星指标

“

不要只盯着模型跑分。
信任是可被度量的。”

OLD PARADIGM

虚荣指标

 ~~模型跑分~~

 ~~参数规模~~



NEW NORTH STAR

METRIC_01

自主运行
时长

Autonomous Runtime

METRIC_02

人工介入
比率

Intervention Rate

ACTION




设计让用户敢于“松手”的产品机制



03

共建 *Co-building*

核心概念



三角博弈

动态平衡示意



DATA INSIGHT

信任的量化

“信任随经验增长”

👤 新手期

~20%

开启全自动批准

< 50 次会话

🏆 专家期


> 40%

开启全自动批准

📈 使用 > 750 次后信任度翻倍

自动化批准率趋势

Claude Code auto-approve rate by experience



“信任并非抽象概念，它在日复一日的交互中被量化。”

Trust is quantified through daily use.



反直觉的中断率

AI 协作中的“老手悖论”

EVIDENCE / 数据铁证

Claude Code interruption rate by experience



NOVICE 新手

~5% 中断率

小心翼翼，倾向于全盘接受 AI 的建议。

EXPERT 老手

~9% 中断率

更敢放手，也更敢随时叫停。

“越是老司机，越喜欢踩刹车。”

CORE INSIGHT

监管策略迁移

从“监考”到“委托”的认知跃迁

新手·监考模式



逐项审批

“我得盯着你，别写错字。”

BEHAVIOR: STEP-BY-STEP

VS

老手·委托模式



监控 + 干预

“方向不对，立刻喊停。”

BEHAVIOR: DELEGATE + MONITOR

💡 核心洞察：你需要的是更强的**方向感**，而不是更细的颗粒度。

Agent 也在“自我监管”

—— 双向奔赴的监管机制

CORE METRIC

主动澄清 vs 人类打断

> **2x** Freq.

在复杂任务中，Agent 主动“暂停”的次数，是人类打断它的 **两倍以上**。

Self-Correction


这不是 Bug，是 Feature。模型在遇到不确定性时，会触发 **自主纠偏** 机制。

#Alignment

#Safety

RISK-AUTONOMY TRADE-OFF

Clarification and interruption rates by goal complexity



SRC: ANTHROPIC

它知道“停下来问路”

Claude 为什么会停?

◆ Agent 主动暂停原因 Top 5 分析

35%

呈现方案选择

🤖 "老板, 我有上中下三策, 请决策"

Agent 并非卡死, 而是主动暂停以对齐目标。这是最高频的“暂停”场景, 体现了其作为协作者的边界感。

TOP 01

21%

索要诊断/测试结果

🔍 "我需要看下报错日志"

12%

索要凭证/访问权

🔑 "需要 API Key 才能继续"

13%

澄清模糊需求

❓ "具体是指哪个文件?"

11%

行动前求确认

⚠️ "我要删库了, 确定吗?"

人类为何打断 AI?

主动权回归：人类主动打断原因 Top 5 分析

NO.1 补上下文 / 纠错

32%

“

“不对，这里应该用 Python...”

⚠ 关键洞察：这不是没礼貌，这是人类在进行高维纠偏 (Alignment)。

太慢 / 废话多

17%

“行了行了，别废话了...”

EFFICIENCY ISSUE



核心逻辑

人类打断
是为了拿回
控制权

7%

够用想自己来

“懂了，剩下我自己写”

7%

想亲自做下一步

“部署这步我来”

5%

需求中途变化

“等等，需求改了”

安全 ≠ 逐项审批

监管误区警示：AI 从业者视角的反思

⚠ 伪安全陷阱

强制 **HITL**
(Human-in-the-loop)

试图对 AI 的每一个动作进行人工盖章。

↘ 生产力窒息

实质安全零提升




VS

✓ 正确范式

共建式监管
(Co-building Oversight)

将安全机制内嵌于开发流程，而非事后拦截。

🛡 动态治理
兼顾效能与合规



API 安全：数据真相

别被恐惧支配，看清 Agent 的真实防线

REAL
DATA

A 预置防护

80%

工具调用
自带“装甲”

Safeguards Enabled



B 人在回路

73%

人类随时准备
接管方向盘

Human-in-the-loop

C 不可逆操作

0.8%

真正的
“核按钮”
极少



04

护城河在行业里

—— 风险-自主性版图与垂直AI的真门槛



VERTICAL AI

MOAT

METHODOLOGY

风险与 自主性量化

量化方法论

核心逻辑：

基于 Tool Call 的单次行为评分，结合聚类分析，构建 AI 安全评估模型。

01 评分维度

1-10 分值区间

Risk vs. Autonomy



02 分析对象

<Tool Call />

针对每一次工具调用进行原子化评估

03 处理方式


Cluster —— 行为聚类

从离散数据中提取 Agent 行为模式



FIG. 01 散点图

What is the risk-autonomy tradeoff in practice?



■ 前沿信号

风险与自主性 矩阵图谱

👥 左下角：拥挤

低风险 + 低自主性。
这是目前 **主流现状** 的红海。

🚩 右上角：稀疏

高风险 + 高自主性。
前沿玩家已进入 **无人区**。

洞察 → 高阶应用正在通过“缝隙”野蛮生长。

高危集群透视

高风险行为分布

01



网络安全

- 权限变更
- 代码注入

敏感操作

02



金融交易

- 自动交易
- 资金流转

资产风险

03



医疗健康

- 病历读写
- 处方建议

隐私与生命

观点重构

数据祛魅

“别被极端案例带偏，看看
表象之下的真相。”

AI 从业者视角

“

👁 表象

AI 正在执行
高危操作

看似失控的极端行为...

INSIGHT / 启示

生产环境依然保守，
安全边界 未被突破。

✔ 真相

Red Teaming
(红队演练)

“故意测试失控风险”



垂直 AI 落地真相

核心壁垒：不仅仅是模型

误区

~~Model
Engineering~~

模型工程

真相

Org
Engineering

组织工程

01

吃透 Legacy Workflow

深入理解二十年旧系统的运行逻辑



02

搞定 Compliance

在监管的缝隙中寻找落地可能



03

推动 Change Management

这比调参数难多了，也值钱多了



AI 产品的护城河

Box CEO Aaron Levie 的判断：拒绝做“套壳”

⚠ 误区

AI Wrapper

(UI + API)

- ✗ 只是外面包一层 UI
- 🔌 简单调用模型 API

⊘ 无护城河

★ 正解

Vertical AI

深度垂直整合

把最脏最累的
 workflows 跑通

🛡 建立高竞争壁垒



核心目标

从“能用” → 规模化

市场上限推演

—— 估值逻辑：从“卖铲子”到“包工程”

LEGACY

SaaS 范式



仅替代 旧软件

"卖给操作软件的人"

TOOL ATTRIBUTE

NEXT GEN

Agent 范式



替代 **操作软件的人**

"人力成本 >> 软件成本"

SERVICE ATTRIBUTE

TAM 扩张

 **10_x**

当服务取代工具，
市场天花板将被重塑。

宏观结构性机会

从 1% 的“工具内卷”到 13% 的“服务蓝海”

现状 软件支出

我们在传统的 IT 领域里厮杀，仅仅是在争夺工具的预算。

1%

GDP 占比

~~存量博弈~~



AI 赋能跨越

机会 商业服务

AI 让我们杀进“重复性语言任务”主导的服务经济腹地。

13%

GDP 占比

🎯 核心战场

INSIGHT // 洞察

我们不只是卖铲子，我们开始直接承接挖矿的任务。



企业应用渗透率的临界点

关键时间窗：未来 18 个月


NEXT

2026 年底

40% 规模化爆发



J-Curve 趋势



NOW / 2025

<5%

早期实验阶段

Gartner 预测 | 行业洗牌的最后 18 个月窗口期



THE
TIPPING
POINT

CONCLUSION

赢家画像

“技术是底座，但行业认知才是那个 1 前面的 0。”

WINNER

01

选准行业 VERTICAL FOCUS

扎进细分领域，而非泛化模型。



02

编织知识 DOMAIN KNOWLEDGE

将几十年行业 Know-how 代码化。



03

变革管理 CHANGE MANAGEMENT

手把手带着客户完成业务闭环。



寻找下一个 独角兽

The Next 300



共建信任

“

“空白不是荒原，
是你的路线图。”

主理人

碳归同传

下期见 →